


Big Data - Øving 5, Høst 2024

Oppgave 1

Klassifikasjonstre med $\text{min_impurity_decrease}=0.01$ og $\text{max_depth}=5$ for [titanic.csv](#).

	precision	recall	f1-score	support
0	0.79	0.77	0.78	87
1	0.66	0.68	0.67	56
accuracy			0.73	143
macro avg	0.72	0.72	0.72	143
weighted avg	0.74	0.73	0.74	143

Figur 1: Klassifikasjonsrapport av tre med parametrene $\text{min_impurity_decrease}=0.01$ og $\text{max_depth}=5$ for datasettet *titanic.csv*.



Figur 2: Klassifikasjonstre med parametrene $\text{min_impurity_decrease}=0.01$ og $\text{max_depth}=5$ for datasettet *titanic.csv*.

Presisjonen for å forutsi at en passasjer på Titanic omkom er på 79% mens presisjonen for å forutsi at en passasjer overlevde er på 66%. Totalt får klassifikasjonstreet en presisjon på 73%


Man kan også lage et mye grunnere tre som også predikerer ok:

Klassifikasjonstre med `min_impurity_decrease=0.01` og `max_depth=1` for [titanic.csv](#).

	precision	recall	f1-score	support
0	0.78	0.79	0.78	87
1	0.67	0.64	0.65	56
accuracy			0.73	143
macro avg	0.72	0.72	0.72	143
weighted avg	0.73	0.73	0.73	143

Figur 3: Klassifikasjons rapport av tre med parametere `min_impurity_decrease=0.01` og `max_depth=1` for datasettet `titanic.csv`.

Sammenlignet med treet på side 1 ser vi at, selv om dette treet er vesentlig grunnere, predikerer det nesten like godt. Presisjonen for å forutsi at en passasjer omkom er 78 %, mens presisjonen for å forutsi at en passasjer overlevde er 67 %. Den totale presisjonen for klassifikasjonstree er, i likhet med forrige tre, 73 %.



Figur 4: Klassifikasjonstre med parametere `min_impurity_decrease=0.01` og `max_depth=1` for datasettet `titanic.csv`.

Oppgave 2

Resultat fra KNN oppgave (Øving 4):

```

k: 11

Classification Report:

```

	precision	recall	f1-score	support
0	0.98	0.99	0.98	95
1	0.98	0.96	0.97	45
accuracy			0.98	140
macro avg	0.98	0.97	0.98	140
weighted avg	0.98	0.98	0.98	140

```

Confusion Matrix:
[[94  1]
 [ 2 43]]

True positive rate: 0.98
True negative rate: 0.98
Accuracy: 0.98

```


Figur 5: Klassifikasjonsrapport og confusion matrix fra KNN-modell øving 4

Klassifikasjons rapport av klassifikasjonstreet med `min_impurity_decrease=0.004` og `max_depth=5` for datasettet [ov4-breast-cancer.csv](#).

	precision	recall	f1-score	support
0	0.97	0.97	0.97	95
1	0.93	0.93	0.93	45
accuracy			0.96	140
macro avg	0.95	0.95	0.95	140
weighted avg	0.96	0.96	0.96	140

Figur 6: Klassifikasjonsrapport av tre med parametrene `min_impurity_decrease=0.004` og `max_depth=5` for datasettet `ov4-breast-cancer.csv`.

Sammenlignet med KNN-oppgaven fra øving 4 ser vi at klassifikasjonstreet har noe lavere presisjon enn KNN-modellen. Dette kan vi lese av kolonnen «precision», der vi får oppgitt true positive rate og false negative rate. I tillegg ser vi at presisjonen for KNN-modellen er 98 %, mens presisjonen for klassifikasjonstreet er 96 %. Kort oppsummert presterer KNN-modellen bedre.



Figur 7: Klassifikasjonstre med parametre $\text{min_impurity_decrease}=0.004$ og $\text{max_depth}=5$ for datasettet *ov4-breast-cancer*.

Oppgave 3


Evalueringemetrikker for regresjonstre av datasettet [BostonHousing.csv](#).

```

R2 score: 0.6577
Mean squared error: 27.1989
Mean absolute error: 3.6625
  
```

Figur 8: Evalueringemetrikker for regresjonstre for datasettet *BostonHousing.csv*

Fra utklippet over ser vi at regresjonstre har en R^2 -score på 0,6577, noe som indikerer at modellen forklarer omtrent 65,77 % av variansen i dataene. Videre ser vi at Mean Squared Error (MSE) er 27,1989, som måler hvor store feilene i prediksjonene er i gjennomsnitt, vektet mot større feil. Mean Absolute Error (MAE) er 3,6625, som representerer gjennomsnittet av de absolutte avvikene mellom de predikerte verdiene og de faktiske verdiene, noe som gir en mer intuitiv forståelse av hvor store feilene typisk er. Disse metrikkene gir oss en indikasjon på at modellen har visse begrensinger som kan påvirke nøyaktigheten.



Figur 9: Regresjonstre av datasettet BostonHousing.csv